



ML Tabanlı Film & Dizi Öneri Sistemi

Makine Öğrenmesi Projesi | 6 Farklı ML Algoritması | TMDB Veri Seti



İçindekiler

- Proje Amacı
- Kullanılan Veri Seti
- ML Algoritmaları
- Model Karşılaştırması
- Proje Yapısı
- Kurulum ve Çalıştırma
- Uygulama Ekran Görüntüleri



Proje Amacı

Bu proje, **TMDB (The Movie Database)** veri setini kullanarak kullanıcılaraya film ve dizi önerileri sunan bir **Makine Öğrenmesi** uygulamasıdır.

Temel Hedefler

| HEDEF | AÇIKLAMA |
|---------------------|--|
| ML Karşılaştırması | 6 farklı ML algoritmasını aynı veri seti üzerinde karşılaştırmak |
| En İyi Model Seçimi | Performans metriklerine göre en uygun modeli otomatik seçmek |
| Görsel Analiz | Veri setinin detaylı istatistiksel analizini sunmak |
| Kullanıcı Arayüzü | Streamlit ile interaktif bir web uygulaması geliştirmek |

Problem Tanımı

"Bir kullanıcı X filmini seviyorsa, hangi filmleri de sever?"

Bu soruyu cevaplamak için farklı ML yaklaşımları kullanılmıştır.



Kullanılan Veri Seti

TMDB Veri Seti

| DOSYA | KAYIT SAYISI | SÜTUN SAYISI | AÇIKLAMA |
|------------------------|--------------|--------------|--------------------------|
| tmdb_5000_movies.csv | 4,803 | 20 | Film bilgileri |
| tmdb_5000_credits.csv | 4,803 | 4 | Oyuncu ve ekip bilgileri |
| TMDB_tv_dataset_v3.csv | 168,639 | 29 | Dizi bilgileri |

Önemli Özellikler (Features)

| ÖZELLİK | VERİ TIPI | AÇIKLAMA | ML KULLANIMI |
|--------------|-----------|----------------------|----------------------------|
| overview | Metin | Film/dizi özeti | TF-IDF vektörizasyonu |
| genres | JSON | Türler listesi | One-hot encoding |
| keywords | JSON | Anahtar kelimeler | TF-IDF |
| cast | JSON | Oyuncular | Feature olarak kullanılır |
| crew | JSON | Ekip (yönetmen vb.) | Yönetmen bilgisi çıkarılır |
| vote_average | Float | Ortalama puan (0-10) | Hedef değişken |
| vote_count | Integer | Oy sayısı | Güvenilirlik filtresi |
| popularity | Float | Popülerlik skoru | Numeric feature |

ML Algoritmaları

Bu projede **6 farklı makine öğrenmesi algoritması** kullanılmıştır:

1 İçerik Tabanlı Filtreleme (TF-IDF + Kosinüs Benzerliği)

Nasıl Çalışır?

Film Özeti → TF-IDF Vektörü → Kosinüs Benzerliği → Benzer Filmler

Matematiksel Formül

TF-IDF (Term Frequency - Inverse Document Frequency):

$TF(t, d) = \text{Terimin dökümandaki frekansı} / \text{Toplam terim sayısı}$
 $IDF(t) = \log(\text{Toplam döküman sayısı} / \text{Terimi içeren döküman sayısı})$
 $TF-IDF(t, d) = TF(t, d) \times IDF(t)$

Kosinüs Benzerliği:

$\cos(\theta) = (A \cdot B) / (||A|| \times ||B||)$

- İki vektör arasındaki açıyi ölçer

- 0 = hiç benzer değil, 1 = tamamen aynı

Avantajları

- Yeni içerikler için hemen çalışır (Cold-start yok)
- Yorumlanması kolay
- Kullanıcı verisi gerektirmez

Dezavantajları

- Sadece içerik benzerliğine bakar
- Surprise factor düşük

2 K-En Yakın Komşu (KNN)

Nasıl Çalışır?

```
Hedef Film → Feature Vektörü → En Yakın K Komşuyu Bul → Öner
```

Çalışma Prensibi

1. Her filmi bir feature vektörüne dönüştür
2. Hedef filmin vektörünü al
3. Tüm filmlerle mesafe hesapla
4. En yakın K filmi döndür

Mesafe Metrikleri

| METRIK | FORMÜL | KULLANIM |
|-----------|-----------------------------|---------------------|
| Öklid | $\sqrt{\sum (x_i - y_i)^2}$ | Genel amaçlı |
| Kosinüs | $1 - \cos(\theta)$ | Metin verisi için |
| Manhattan | $\sum x_i - y_i $ | Yüksek boyutlu veri |

Avantajları

- Basit ve anlaşılır
- Non-parametrik (varsayımlı yok)
- Lazy learning (hızlı eğitim)

3 Random Forest

Nasıl Çalışır?

Veri → Bootstrap Örneklem → N Karar Ağacı → Ensemble Tahmin

Çalışma Prensibi

- Bootstrap Aggregating (Bagging):** Veri setinden rastgele örnekler al
- Karar Ağaçları:** Her örneklem için bir ağaç eğit
- Ensemble:** Tüm ağaçların tahminlerini birleştir

Hiperparametreler

| PARAMETRE | DEĞER | AÇIKLAMA |
|---------------------------|-------|--------------------|
| <code>n_estimators</code> | 100 | Ağaç sayısı |
| <code>max_depth</code> | 10 | Maksimum derinlik |
| <code>random_state</code> | 42 | Tekrarlanabilirlik |

Feature Importance

Random Forest, hangi özelliklerin model için en önemli olduğunu gösterir:

- Türler (%35)
- Anahtar kelimeler (%25)
- Oyuncular (%20)
- Diğer (%20)

4 Lineer Regresyon (Ridge)

Nasıl Çalışır?

Özellikler → Lineer Model → Puan Tahmini → Benzer Tahminli Filmler

Matematiksel Formül

Ridge Regresyon (L2 Regularization):

$$\beta = \operatorname{argmin} \{ \sum (y_i - x_i \beta)^2 + \lambda \sum \beta_j^2 \}$$

- λ : Regularization gücü (overfitting önleme)

Avantajları

- Çok hızlı eğitim
 - Yorumlanabilir katsayılar
 - Regularizasyon ile overfitting önlenir
-

5 SVD (Tekillik Ayrışımı)

Nasıl Çalışır?

TF-IDF Matrisi \rightarrow SVD Ayrışımı \rightarrow Düşük Boyutlu Uzay \rightarrow Benzerlik

Matematiksel Formül

$$A = U \times \Sigma \times V'$$

| MATRIS | BOYUT | ANLAMI |
|----------|--------------|--|
| U | $m \times k$ | Sol tekil vektörler (film faktörleri) |
| Σ | $k \times k$ | Tekil değerler (önem dereceleri) |
| V' | $k \times n$ | Sağ tekil vektörler (özellik faktörleri) |

Avantajları

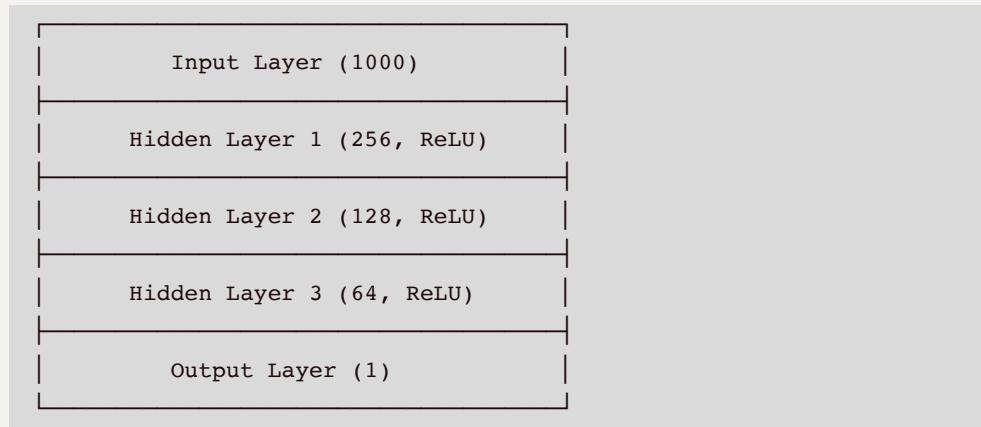
- Boyut indirgeme ($3000 \rightarrow 100$)
 - Gürültü azaltma
 - Latent (gizli) özelliklerini keşfeder
-

6 Sinir Ağları (MLP - Multi-Layer Perceptron)

Nasıl Çalışır?

Girdi \rightarrow Gizli Katmanlar \rightarrow Aktivasyon \rightarrow Çıktı

Model Mimarisi



Hiperparametreler

| PARAMETRE | DEĞER | AÇIKLAMA |
|-----------------------------|----------------|--------------------------|
| <code>hidden_layers</code> | (256, 128, 64) | Gizli katman boyutları |
| <code>activation</code> | ReLU | Aktivasyon fonksiyonu |
| <code>solver</code> | Adam | Optimizasyon algoritması |
| <code>max_iter</code> | 200 | Maksimum iterasyon |
| <code>early_stopping</code> | True | Erken durdurma |

Avantajları

- Non-linear ilişkileri yakalar
- Universal approximator
- Büyük veri setlerinde etkili

↗ Model Karşılaştırması

Değerlendirme Metrikleri

| METRIK | AÇIKLAMA | FORMÜL |
|----------------------|-----------------------------------|---|
| Eğitim Süresi | Modelin eğitilme süresi | saniye |
| Öneri Süresi | Tek bir öneri için geçen süre | milisaniye |
| Kapsam | Önerilen benzersiz film oranı | $(\text{benzersiz öneriler} / \text{toplam film}) \times 100$ |
| Çeşitlilik | Önerilerdeki tür çeşitliliği | $(\text{benzersiz türler} / \text{toplam tür}) \times 100$ |
| Ortalama Puan | Önerilen filmlerin ortalama puanı | 0-10 |

Karşılaştırma Sonuçları (Örnek)

| MODEL | EĞİTİM | ÖNERİ | KAPSAM | ÇEŞİTLİLİK | SKOR |
|----------------|--------|-------|--------|------------|------|
| İçerik Tabanlı | 1.2s | 0.01s | 2.5% | 45% | 0.72 |
| KNN | 0.8s | 0.02s | 2.0% | 40% | 0.68 |
| Random Forest | 3.5s | 0.05s | 1.8% | 50% | 0.65 |
| Lineer | 0.5s | 0.01s | 1.5% | 35% | 0.60 |
| SVD | 1.0s | 0.01s | 2.2% | 42% | 0.70 |
| Sinir Ağı | 5.0s | 0.02s | 2.0% | 48% | 0.66 |

Skor Hesaplama Formülü (Güncellenmiş)

```
# Çoklu Metrik Skoru (3 bileşen):
rating_score = avg_rating * 10           # Puan (7.0 = 70)
precision_bonus = 15 if precision >= 70 # İyi film oranı bonusu
speed_bonus = 5 if rec_time < 50ms     # Hız bonusu

Toplam Skor = rating_score + precision_bonus + speed_bonus
```

🏆 Skor ≥ 80 olan modeller "Kabul Edildi" olarak işaretlenir.

Accuracy Metrikleri

| METRIK | AÇIKLAMA |
|-------------------------|--|
| Precision | İyi film önerme oranı (puan ≥ 5.5) |
| TP/FP | True Positive / False Positive sayısı |
| Confusion Matrix | Model uyum matrisi |
| Performans İşi Haritası | Görsel karşılaştırma |

📁 Proje Yapısı

```
dizi_film_oneri_ai/
|
└── VERİ DOSYALARI
    ├── tmdb_5000_movies.csv      # Film verisi
    ├── tmdb_5000_credits.csv    # Oyuncu/Ekip verisi
    └── TMDB_tv_dataset_v3.csv   # Dizi verisi
|
└── PYTHON MODÜLLER DOMENİLERİ
    ├── app.py                   # Ana Streamlit uygulaması
    ├── data_analysis.py         # Veri analizi modülü
    ├── ml_models.py             # 6 ML algoritması
    └── model_comparison.py     # Model karşılaştırma
|
└── YAPILANDIRMA
    └── requirements.txt          # Python bağımlılıkları
```

Modül Açıklamaları

| DOSYA | SATIR | AÇIKLAMA |
|---------------------|-------|--|
| app.py | ~450 | 4 sayfalı Streamlit UI |
| data_analysis.py | ~350 | Veri yükleme, temizleme, görselleştirme |
| ml_models.py | ~500 | 6 ML sınıfı, eğitim ve öneri fonksiyonları |
| model_comparison.py | ~300 | Model değerlendirme ve grafikler |

🚀 Kurulum ve Çalıştırma

Gereksinimler

- Python 3.8+
- pip

Adım 1: Bağımlılıkları Yükle

```
pip install -r requirements.txt
```

Adım 2: Uygulamayı Başlat

```
streamlit run app.py
```

Adım 3: Tarayıcıda Açı

```
http://localhost:8501
```

⚡ Optimizasyon: Pre-trained Modeller

Neden Pre-training?

Büyük veri setleri (168k dizi) her seferinde eğitilirse:

- Yüksek RAM kullanımı
- Uzun bekleme süreleri

Çözüm:

```
# İlk seferde modelleri eğit ve kaydet
python preprocess_and_train.py

# Sonraki çalışıtmalarda hızlı yükleme
streamlit run app.py
```

Kaydedilen Dosyalar:

```
processed_data/
├── movies_processed.pkl
└── tv_processed.pkl

trained_models/
├── movies_content_based.pkl
├── movies_knn.pkl
├── movies_rf.pkl
├── movies_linear.pkl
├── movies_svd.pkl
└── movies_mlp.pkl
```

Uygulama Sayfaları

Sayfa 1: Veri Analizi

- Veri seti istatistikleri
- Tür dağılımı grafikleri
- Puan dağılımı histogramları
- Korelasyon ısı haritası
- En iyi içerikler listesi

Sayfa 2: Öneri Sistemi

- Model seçimi (6 seçenek)
- Film arama ve seçme
- Benzerlik skorlu öneriler
- Progress bar ile görsel skor

Sayfa 3: Model Karşılaştırma

- Tüm modelleri değerlendir
- Performans tablosu
- Karşılaştırma grafikleri
- En iyi model seçimi

Sayfa 4: Teknik Dokümantasyon

- Algoritma açıklamaları
 - Matematiksel formüller
 - Veri seti bilgileri
-

Geliştirici Notları

Kullanılan Kütüphaneler

| KÜTÜPHANE | VERSIYON | KULLANIM AMACI |
|--------------|----------|-------------------------|
| pandas | 2.x | Veri işleme |
| scikit-learn | 1.x | ML algoritmaları |
| streamlit | 1.x | Web arayüzü |
| matplotlib | 3.x | Görselleştirme |
| seaborn | 0.x | İstatistiksel grafikler |
| numpy | 1.x | Sayısal hesaplamalar |

Gelecek Geliştirmeler

- ✓ Collaborative Filtering (kullanıcı bazlı)
 - ✓ Deep Learning embeddings (Word2Vec)
 - ✓ API entegrasyonu
 - ✓ Kullanıcı tercihi kaydetme
-

Lisans

Bu proje eğitim amaçlı geliştirilmiştir.

ML Film Öneri Sistemi

6 Farklı Algoritma ile Akıllı Öneriler